2026년도 1학기 기계학습
Mini Research Project

과제명	국문	앙상블 머신러닝 모델을 활용한 좌석 등급별 항공권 가격 예측 및 요인 분석
	영문	Airfare Price Prediction and Factor Analysis Using Ensemble Machine Learning Models

조장: 김 민 서

조원: 김 예 린

이 소 민

이 예 빈

이 채 민

1. Introduction

1.1 연구의 배경

최근 항공 산업은 실시간 수요, 예약 시점, 거시 경제적 요인을 복합적으로 반영하는 동적 가격 결정(Dynamic Pricing) 메커니즘에 의해 운영된다. 이러한 가격 변동성은 항공사에는 수익 극대화의 기회를 제공하지만, 소비자에게는 정보의 비대칭성과 불확실성을 초래한다. 본 연구는 항공권 가격의 비선형적인 변동성을 학습하고, 특히 “좌석 등급(Economy와 Business)”에 따른 가격 결정 구조의 차이를 정량적으로 분석하여 소비자에게는 최적의 구매 시점과 가격을 항공사에는 정교한 운임 전략 수립의 근거를 제공하는 것을 목적으로 한다.

1.2 기존 방법론의 한계점

대부분의 기존 접근법은 전체 항공권 데이터를 하나로 통합하여 단일 모델로 학습시키는 방식을 취하고 있다. 이는 좌석 등급별(Economy, Business)로 타겟 고객층의 예약 패턴과 가격 결정 로직이 확연히 다름에도 불구하고, 각 등급 고유의 변동 특성을 희석시켜 결국 예측의 정확도와 인사이트 도출의 신뢰성을 떨어뜨리는 결과를 초래했다.

또한, 기존의 항공권 가격 예측 연구들은 주로 선형 회귀(Linear Regression)나 단일 의사결정 나무(Decision Tree)와 같은 전통적인 통계 모델에 의존해 왔다. 그러나 이러한 방식은 복잡한 동적 가격 체계에서 발생하는 급격한 변동 구간을 정교하게 학습하지 못하며, 모델의 표현력 부족으로 인해 실제 가격과 예측치 사이의 차이를 효과적으로 제어하지 못하는 한계를 보였다.

1.3 연구 목적

본 연구의 목적은 항공권 가격의 비선형적 변동성을 정밀하게 포착하기 위해 데이터 전처리 최적화와 앙상블 학습을 결합한 하이브리드 예측 프레임워크를 제안하는 데 있다.

이를 위해 특성 공학(Feature Engineering)을 통해 각 등급에 특화된 가격 결정 로직을 명확히 식별하고 연산 효율성을 확보한다. 둘째, 배깅(Bagging)과 부스팅(Boosting) 기반의 알고리즘을 스태킹(Stacking) 기법으로 통합하여 단일 모델의 한계를 극복하는 하이브리드 앙상블 아키텍처를 구축한다. 결과적으로 본 연구는 모델의 편향과 분산을 최소화하여 일반화 성능을 극대화함으로써, 급격한 운임 변동 상황에서도 높은 예측 안정성과 정밀도를 동시에 확보할 수 있는 최적의 가격 예측 모델을 도출하는 것을 최종 목적으로 한다.

1.4 핵심 아이디어와 기여점

첫째, 구조적 메커니즘을 명확히 규명하였다. 단순히 결과값만을 도출하는 '블랙박스' 형태의 모델링에서 벗어나, 특성 중요도(Feature Importance) 분석을 병행함으로써 좌석 등급별로 가

격에 영향을 미치는 핵심 변수를 해석적으로 제시한다. 이를 통해 이코노미석과 비즈니스석의 가격 변동 요인이 어떻게 다른지 정량적으로 비교할 수 있는 근거를 마련한다.

둘째, 예측 성능을 극대화하여 실질적인 분석 역량을 높인다. 기존의 선형 모델이나 단일 의사결정 나무가 해결하지 못했던 비즈니스 등급의 불규칙한 가격 변동성과 불확실성을 앙상블 모델을 통해 정량화한다. 이는 예측 오차를 최소화함과 동시에 모델의 신뢰도를 높이는 효과를 낳는다.

셋째, 좌석 등급별 특성에 최적화된 독립적 모델링 체계를 구축하여 분석의 정밀도를 높인다. 가격 민감도가 높고 예약 패턴이 정형화된 이코노미석과 일정의 편의성이 중시되며 비선형적 변동이 큰 비즈니스석의 데이터를 완전히 분리하여 모델링을 수행한다. 이를 통해 각 등급별 가격 결정에 지배적인 영향을 미치는 핵심 변수가 확연히 다름을 확인하며, 등급 간 상이한 가격 변동 메커니즘을 식별할 수 있는 통합적인 분석 프레임워크를 제시한다.

마지막으로, 본 연구는 실무적 가치를 제공한다. 소비자 측면에서는 비용 절감을 위한 최적의 구매 시점인 '최적 구매 윈도우(Optimal Buying Window)'에 대한 구체적인 가이드라인을 제공받을 수 있다. 동시에 항공사 측면에서는 데이터에 기반한 정교한 동적 운임 전략을 수립하고 각 좌석 등급별 고객 특성에 맞춘 차별화된 마케팅 정책을 수립하는 데 필수적인 기초 자료로 활용할 수 있다는 점에서 큰 의의가 있다.

2. Related Work

2.1 선행 연구 소개

첫째, Kalampokas 외(2023)의 논문 "A Holistic Approach on Airfare Price Prediction Using Machine Learning Techniques"은 기존 가격 최적화 시스템이 급격한 시장 변화와 동적 가격 정책의 적응 속도를 따라가지 못하는 한계를 극복하기 위해, 항공권 가격 예측을 위해 총 16개의 인공지능 모델을 종합적으로 비교 평가하였다. 해당 연구는 랜덤 포레스트(Random Forest), 그래디언트 부스팅(Gradient Boost)을 포함한 8개의 머신러닝 앙상블 모델과 딥러닝(DL), 양자 머신러닝(QML) 아키텍처를 병렬로 테스트하였다. 실험 결과, 앙상블 모델들이 안정적인 예측력을 보였으나 궁극적으로는 딥러닝 및 양자 모델이 89%~99%의 가장 뛰어난 성능을

달성함을 확인하였다. 이는 본 연구가 개별 트리 기반 앙상블 모델들의 단순 비교를 넘어, 이들의 예측력을 하나로 결합하고 최적화하는 '스태킹(Stacking) 앙상블' 기법으로 나아가야 할 강력한 방법론적 당위성을 제공한다.

둘째, Deng(2024)의 "International Flight Fare Prediction" 연구에서는 복잡하고 동적으로 변동하는 항공사들의 가격 정책으로 인해 소비자가 최저가 항공권을 확보하기 매우 어려워진 현실적인 문제를 해결하고자, 선형 회귀(Linear Regression), 의사결정 나무(Decision Tree), 랜덤 포레스트(Random Forest) 등 다양한 알고리즘의 예측 성능을 정밀하게 검증하였다. 해당 연구는 항공권 가격 결정에 지배적인 영향력을 미치는 핵심 변수로 좌석 등급(Cabin Class)을 꼽았으며(상관계수 -0.94), 편명(Flightnumbers)과 운항 시간(Duration) 등도 유의미한 변수로 도출하였다. 모델 성능 평가 결과, 랜덤 포레스트 모델이 결정계수(R^2) 0.989 및 평균 절대 오차(MAE) 888.96을 기록하며, 선형 회귀(R^2 0.905, MAE 4621.92)와 단일 의사결정 나무(R^2 0.983, MAE 905.56) 대비 오차를 획기적으로 줄인 가장 우수한 정밀도를 달성함을 입증하였다. 이는 본 연구가 앙상블 모델을 활용하여 비선형적인 항공권 가격 패턴을 학습하고 예측의 신뢰도를 극대화하려는 방법론적 근거를 뒷받침한다.

셋째, Ertürk 외(2025)의 "Large-Scale Airline Ticket Price Prediction Using Ensemble Machine Learning Algorithms" 연구는 수요 변동, 시장 경쟁, 예약 시점 등 다중 요인에 의해 급변하는 항공권 가격의 복잡성을 해결하고, 소규모 데이터에 의존했던 기존 연구들의 한계를 극복하고자 대용량 정형 데이터 처리를 위해 고도화된 앙상블 기법을 적용하였다. 해당 연구는 약 30만 건 이상의 항공권 데이터를 바탕으로 다양한 머신러닝 알고리즘을 비교 분석하였으며, 특히 XGBoost 모델을 통해 (R^2) 0.98 및 평균 절대 오차(MAE) 2035.51이라는 고도의 정밀도를 달성하였다. 이를 통해 이코노미 및 비즈니스 클래스, 예약 시점 등 다양한 변수가 얽힌 복잡한 데이터 환경에서 앙상블 및 부스팅 기법(XGBoost, Random Forest)이 오차를 획기적으로 줄이고 예측 성능을 극대화할 수 있음을 실증하였다.

넷째, Korkamz (2024)의 논문 “Flight Price Prediction using Machine Learning Method”은 전통적인 가격 책정 모델이 항공권 가격의 복잡하고 급격한 변동 패턴을 제대로 포착하지 못하는 한계를 극복하고자, Multiple Linear Regression, Decision Tree, SVM, Neural Network, Gaussian Process Regression(GPR) 등 다양한 모델을 적용하여 다양한 변수들을 활용한 항공권 가격 예측 및 모델의 성능을 비교하였다. 특히 커널 기반 모델(GPR)을 활용하여 비선형 관계를 반영하였다. 그 결과 GPR 모델이 가장 높은 성능 (R^2 = 0.90)을 보이며, 비선형 모델이 가격 예측에 효과적임을 확인하였다.

다섯째, Chavan 외(2024)의 논문 "Comparative Analysis of Machine Learning Models for Accurate Flight Price Prediction"은 전통적인 예측 방식으로는 계절성, 수요, 노선 인기도 등에 의해 급변하는 항공권 가격의 역동성을 포착하기 어렵다는 문제를 해결하고자, 머신러닝 앙상블 기법의 우수성을 입증함과 동시에 단일 모델이 지닌 한계를 명확히 지적하였다. 해당 연구는 랜덤 포레스트와 그래디언트 부스팅을 통해 R^2 0.90~0.92 수준의 높은 예측 성능을 달

성하였으나, 개별 앙상블 알고리즘의 한계를 보완하고 정확도를 한층 더 높이기 위한 필수 향후 과제로 여러 모델의 장점을 결합하는 '메타 러너(Meta-learner)' 기반의 '스태킹(Stacking) 모델' 도입을 명시적으로 제안하였다. 이는 본 연구가 개별 트리 기반 부스팅 모델(XGBoost, LightGBM)의 단순 비교 평가에 그치지 않고, 이를 메타 러너(Ridge)와 결합하여 예측 안정성과 일반화 성능을 극대화하는 고도화된 스태킹 앙상블 프레임워크를 최종 제안하는 데 가장 강력한 학술적 타당성과 방법론적 근거를 제공한다.

2.2 선행 연구의 한계점 및 시사점

	주요 연구 내용	한계점	본 연구의 차별성
선행 연구 1	16개 예측 모델(ML, DL 등)의 단순 병렬 비교	기초 변수만 활용, 모델 간 결합(Stacking) 시도 부재	고도화된 특성 공학 및 스태킹 앙상블 융합 적용
선행 연구 2	전 좌석 등급 데이터를 일괄 병합하여 학습	좌석 등급별 고유의 가격 변동 메커니즘 희석	좌석 등급별 분리 학습으로 클래스 특화 예측
선행 연구 3	연속형 변수(예약 일수 등)를 모델에 단순 수치 반영	데이터 비대칭성(왜도) 및 이상치에 대한 심층적 통제 부재	로그 변환 및 정교한 구간화로 왜곡 보정 및 패턴 학습 극대화
선행 연구 4	비선형 모델 및 단일 앙상블(배깅, 부스팅) 개별 평가	단일 및 동종 앙상블에 국한되어 편향/분산 한계 존재	이기종 알고리즘의 강점을 결합한 하이브리드 아키텍처 구축
선행 연구 5	여러 단일 앙상블 알고리즘의 예측 수치 중심 비교	블랙박스 모델의 해석력 부족 및 메타 러너(Meta-learner) 부재	특성 중요도(Feature Importance) 분석으로 명확한 모델 해석력 확보

항공권 가격 예측과 관련된 기존의 연구들은 주로 통계적 모델이나 기본적인 머신러닝 알고리즘을 활용해 왔다. 초기 연구들은 다중 선형 회귀(Multiple Linear Regression)를 통해 변수 간의 관계를 파악하려 했으나, 항공권 가격 특유의 복잡한 비선형적 변동성을 학습하는 데 한계가 있었다. 이후 도입된 단일 의사결정 나무(Decision Tree) 모델 역시 특정 데이터에 과도하게 적합되는 과적합(Overfitting) 문제로 인해 예측 안정성이 낮다는 한계가 존재했다.

특히 대다수의 선행 연구에서 발견되는 공통적인 단점은 데이터의 이질성을 간과했다는 점이다. 운임 산정 방식과 예약 패턴이 상이한 이코노미석과 비즈니스석 데이터를 일괄적으로 병합하여 모델링 함에 따라, 각 등급이 지닌 고유한 가격 변동 메커니즘을 정밀하게 포착하지 못했다. 또한, 단순한 알고리즘(배깅 또는 부스팅 등 단일 앙상블 기법) 사용에 그쳐 모델의 편향(Bias)과 분산(Variance) 문제를 동시에 해결하지 못했으며, 결과값에 대한 논리적 근거를 제시하는 설명력을 충분히 확보하지 못했다.

2.3 본 연구의 차별성

본 연구는 기존 항공권 가격 예측 모형들이 지닌 방법론적 한계를 보완하고 실제적인 예측 성능을 극대화하기 위해 다음과 같은 세 가지 핵심 전략을 도입하였다.

첫째, 좌석 등급 기반의 맞춤형 분리 학습(Segmented Learning) 적용이다. 선행 연구들처럼

전 좌석 데이터를 일괄적으로 병합하여 학습시킬 경우, 각 등급 고유의 가격 변동 패턴이 희석되는 문제가 발생한다. 본 연구는 이코노미와 비즈니스 클래스의 데이터를 독립적인 아키텍처로 분리 학습시킴으로써, 개별 클래스에 내재된 세밀한 가격 결정 메커니즘을 온전히 반영한 예측 모델을 구현한다.

둘째, 하이브리드 스태킹 앙상블(Hybrid Stacking Ensemble) 프레임워크 구축이다. 단일 알고리즘이 갖는 편향 및 분산의 약점을 극복하기 위해, 예측 안정성이 뛰어난 랜덤 포레스트(Random Forest)와 높은 정밀도를 자랑하는 XGBoost, LightGBM을 1차 모델로 결합한다. 이후 각 모델의 예측값에 최적의 가중치를 부여하는 메타 러너(Meta-learner)를 2차로 통과시켜, 데이터의 비선형적 패턴을 완벽히 포착하고 최종 예측의 신뢰도를 극대화한다.

셋째, 다차원적 평가지표를 통한 객관적인 성능 개선 입증이다. 본 연구는 RMSE 지표를 활용해 실제 시장 가격과 모델 예측치 간의 오차를 엄밀하게 측정함과 동시에, 데이터 변동성에 대한 설명력을 나타내는 R^2 지표를 교차 검증한다. 특히, 단순 베이스라인(Baseline) 모델 대비 제안된 스태킹 앙상블 모델이 달성한 R^2의 향상 폭을 추적 분석하여, 본 프레임워크가 항공 시장의 불확실성을 얼마나 효과적으로 통제하는지 학술적으로 증명한다.

3. Proposed Method

3.1 연구 프레임워크 및 전체 접근 방식 (Overall Approach)

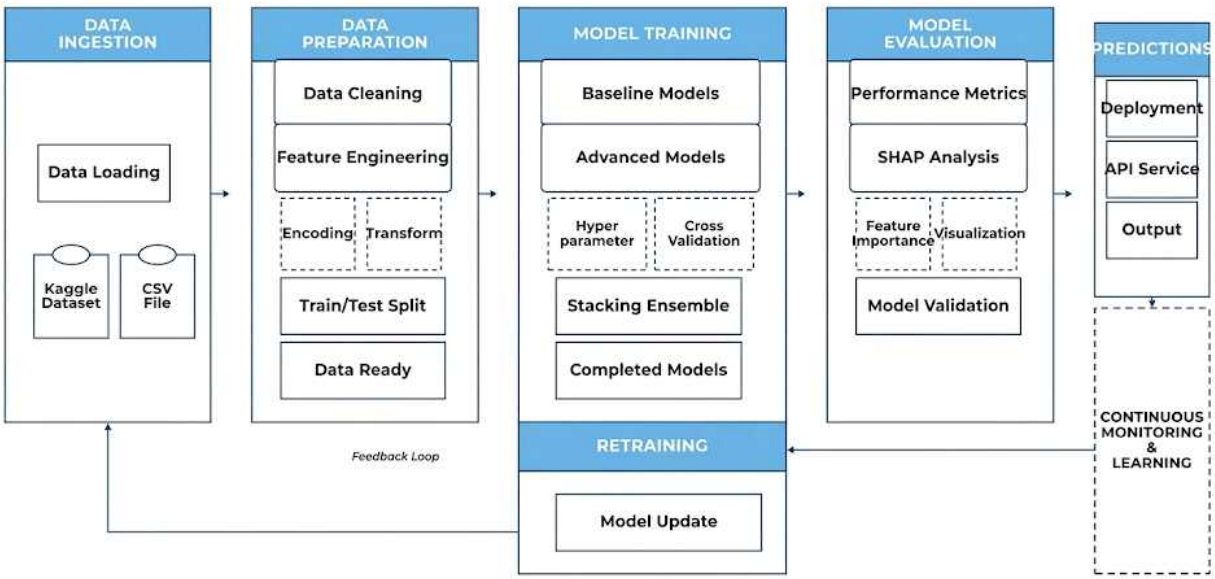

본 연구는 항공권 가격의 복잡한 변동성을 규명하고, 최종가격을 높은 정확도로 예측하기 위해 기계학습(Machine Learning) 기반의 체계적인 연구 프레임워크를 제안한다. 연구의 전체적인 접근 방식은 데이터 수집 및 전처리, 특성 공학(Feature Engineering), 단일 모델의 병렬

학습, 그리고 앙상블 기법을 활용한 최종 예측 및 성능 평가의 단계적 파이프라인으로 구성된다.

연구의 신뢰성을 확보하기 위해 가장 먼저 원시 데이터(Raw Data) 내의 노이즈를 제거하고, 기계학습 알고리즘의 학습 효율을 극대화할 수 있도록 특성 공학(Feature Engineering)을 적용하여 데이터의 품질을 고도화한다. 이 과정에서 다중공선성과 과적합을 유발할 수 있는 불필요한 변수들을 통제하기 위해 파생 변수 생성 및 범주형 데이터의 일괄적인 원-핫 인코딩, 그리고 타겟 변수의 정규화를 거쳐 모델 학습을 위한 최적의 데이터셋을 구축한다.

본 연구의 핵심 모델링 접근 방식은 단일 예측 모델이 가지는 통계적 편향과 한계를 극복하기 위해 다수의 이질적인 기계학습 알고리즘을 융합하는 스태킹 앙상블(Stacking Ensemble) 기법을 채택한 점이다. 이를 위해 선형적 관계를 파악하는 다중 선형 회귀(MLR), 릿지(Ridge), 라쏘(Lasso)와 더불어, 데이터의 비선형적 패턴과 복잡한 상호작용을 포착하는 데 탁월한 랜덤 포레스트(Random Forest), XGBoost, LightGBM 모델로 학습을 진행한다.

이후 각 기반 모델이 도출한 1차 예측값들을 새로운 입력 데이터(Meta Feature)로 취합하고, L2 규제인 릿지(Ridge)를 메타 모델(Meta Learner)로 설정하여 최종 항공권 가격을 도출한다. 도출된 예측 결과는 RMSE, MAE, R^2 등의 평가 지표를 통해 기존 단일 모델들과의 성능을 비교 검증하고 특성 중요도 분석을 병행하여 실제 항공권 가격 결정에 결정적인 영향을 미치는 주요 요인들을 해석론적 관점에서 도출하고 분석한다.

3.2 Baseline 모델 및 제안 기법

베이스라인 모델 : 다중 선형 회귀(Multiple Linear Regression)을 통해 변수 간의 선형적 관계를 파악하고, 릿지 (Ridge)와 라쏘 (Lasso) 회귀를 통해 정규화 효과와 다중공선성 문제를 검토한다. 이는 추후 투입될 비선형 모델들의 성능 향상 폭을 측정하는 객관적인 기준점이 된다. 또한, 기존 연구에서 예측력이 검증된 랜덤 포레스트 (Random Forest)를 베이스라인 모델로 설정한다.

기반 모델(Base Model) 구축: 기존 연구에서 예측력이 검증된 랜덤 포레스트(Random Forest)와 XGBoost 외에, 대용량 범주형 데이터 처리에 최적화된 LightGBM을 새롭게 도입한다. LightGBM은 리프 중심 트리 분할(Leaf-wise growth) 방식을 통해 학습 속도를 비약적으로 단축하며, 항공사 및 노선과 같은 고차원 범주형 변수를 효율적으로 처리할 수 있다.

스태킹 앙상블(Stacking Ensemble) 제안: 개별 알고리즘이 지닌 편향(Bias)과 분산(Variance)의 한계를 상호 보완하기 위해 스태킹 앙상블 기법을 제안한다. 앞서 구축한 Random Forest, XGBoost, LightGBM을 베이스 러너(Base Learner)로 활용하고, 과적합 방지에 효과적인 릿지(Ridge) 회귀를 메타 러너(Meta Learner)로 결합함으로써 예측의 신뢰도와 정밀도를 극대화한다.

3.3 Baseline 대비 개선 아이디어 및 변경

본 연구에서 사용되는 주요 알고리즘의 역할과 차별적 특징은 다음과 같다.

모델 구분	핵심 특징 및 차별점	본 연구에서의 역할
MLR	해석 용이성을 갖춘 기준 모델	비선형 모델과의 성능 차이 정량화 및 기준점 제공
Ridge/Lasso	L1/L2 정규화 적용	고차원 특성 처리 및 불필요한 변수 자동 선택
Random Forest	배깅(Bagging) 기반 비선형 관계 포착	안정적인 비선형 패턴 학습 및 변수 중요도 추출
XGBoost	정밀한 그래디언트 부스팅 구현	복잡한 가격 변동 패턴 학습 및 최적 성능 도출
LightGBM	고속 학습 및 범주형 특성 직접 처리	대용량 데이터의 효율적 처리 및 XGBoost와 비교
Stacking	메타 러너 기반의 다중 모델 결합	최고 예측 성능 달성 및 좌석 등급별 분리 예측

3.4 제안 방법론의 기대효과 및 기여점

본 연구에서 제안하는 좌석 등급 분리 학습 전략은 이코노미와 비즈니스 각 클래스에 내재된 고유의 다이내믹 프라이싱 구조를 데이터 훼손 없이 온전히 학습할 수 있게 한다. 또한 병렬 트리 기반으로 분산을 줄이는 배깅 기법(Random Forest)과 순차적 학습으로 편향을 제어하는 부스팅 기법(XGBoost, LightGBM)을 스태킹 앙상블로 융합함으로써 단일 모델이 갖는 통계적 취약점을 상호 보완한다. 이를 통해 선행 연구의 단일 모델 기반 결정계수 임계치(R^2 =0.87 수준)를 뛰어넘는 고도의 예측 정확도와 일반화 성능을 달성할 수 있을 것으로 기대된다.

본 연구에서 제안하는 앙상블 기반의 분석 프레임워크는 기존 선행 연구들과 차별화되는 몇 가지 핵심적인 기대 효과를 지닌다. 우선, 병렬 트리 기반으로 분산을 줄이는 배깅 기법(Random Forest)과 순차적 학습으로 편향을 제어하는 부스팅 기법(XGBoost, LightGBM)을 스태킹 앙상블(Stacking Ensemble) 기법을 통해 개별 모델의 예측 오차를 상호 보완함으로써, 기존 연구의 성능 임계치로 평가받던 결정계수(R^2=0.871)를 상회하는 고정밀 예측 모델을 구현할 수 있을 것으로 판단된다.

또한, 연산 효율성 측면에서는 LightGBM 알고리즘을 적극 활용함으로써 XGBoost 대비 약 7배 빠른 학습 속도를 달성할 수 있다. 이러한 성능적 우위는 대규모 실시간 데이터 스트림이 발생하는 실제 항공 예약 환경에서 모델의 업데이트 및 재학습 주기를 단축시켜 실무적 활용 가능성을 크게 제고한다.

나아가 본 연구는 모델의 예측 결과에 대한 해석력을 강화 및 등급별 가격 결정 메커니즘의 실증적 규명이다. 본 연구는 복잡한 블랙박스 모델의 한계를 극복하기 위해 알고리즘별 특성 중요도(Feature Importance) 및 회귀 계수(Coefficient) 분석 방법론을 적용한다. 이를 통해 각 변수가 최종 가격 결정에 기여하는 정도를 정량적으로 도출하여 제시한다. 특히 이코노미와 비즈니스 클래스를 독립적인 모델로 분리하여 학습함으로써, 각 좌석 등급별로 상이하게 작용하는 다이내믹 프라이싱(Dynamic Pricing) 전략의 실체를 비교 분석하고 데이터에 기반한 구체적인 인사이트를 제공한다는 점에서 학술적으로 중요한 기여를 한다.

4. Experiment & Evaluation

4.1 Dataset

본 연구에서는 항공권 가격 예측 모델의 성능을 평가하기 위하여 캐글(Kaggle)에서 제공되는 'Flight Price Prediction' 정형 데이터셋(Clean_Dataset.csv)을 활용하였다. 해당 데이터셋은 실제 항공권 예약 플랫폼에서 수집된 인도 국내선 항공권 정보를 포함하고 있으며 전체 데이터의 규모 및 구성 요소는 다음과 같다.

본 데이터셋은 약 30만 건의 레코드를 보유하고 있으며, 예측의 핵심이 되는 독립 변수들은 총 5개의 주요 범주형 클래스 체계로 구성되어 있다.

전체 데이터 수 (Samples): 300,153개
전체 피처 수 (Features): 11개 (Target 변수 포함)

주요 범주형 클래스 구성:
항공사 클래스 (Airline): 6종 (Vistara, Air India 등)
좌석 등급 클래스 (Class): 2종 (Economy, Business)
노선 및 도시 클래스 (City): 6종 (Delhi, Mumbai 등 주요 거점 도시)
시간대 클래스 (Time): 6종 (Morning, Evening 등)
경유지 클래스 (Stops): 3종 (0, 1, 2회 이상)

4.2 Baseline Method

본 연구에서는 항공권 가격 예측 성능을 비교·분석하기 위해 Multiple Linear Regression, Lasso, Regression, Random Forest 를 베이스라인 모델로 설정하였다. 각 모델은 서로 다른 학습 방식과 특성을 가지며 이를 통해 데이터의 선형적 관계와 비선형적 패턴을 동시에 분석하고자 하였다.

먼저, Multiple Linear Regression 모델은 입력 변수와 출력값 사이의 선형 관계를 가정하는 가장 기본적인 회귀 모델로, 별도의 하이퍼파라미터 튜닝 없이 기본 설정을 사용하였다. 이는 모델 구조가 단순하고 해석이 용이하다는 장점이 있으며, 다른 모델들과의 성능 비교를 위한 베이스라인 역할을 수행한다.

다음으로, L1 정규화를 통해 중요하지 않은 변수의 계수를 0으로 만들어 변수 선택 효과를 제공하는 Lasso를 이용했다. 본 연구에서는 최적의 α 값을 찾기 위해 다양한 범위의 값(0.01부터 100.0까지)을 탐색 후보로 설정하고 R^2 점수를 기준으로 했다. 이때, α 값이 클 경우 중요한 변수까지 제거될 수 있고 반대의 경우 정규화 효과가 미미해지는 점을 고려하여 0.01로 설정하였다. 또한, Ridge는 기존 선형 회귀 모델에 L2 규제항을 추가하여 모델의 복잡도를 제어하는 모델로 최적의 α값인 10.0으로 설정하였다. 릿지는 라쏘와 더불어서 선형적 관계를 기반으로 데이터의 기본적인 경향성을 파악하기에 적합하며 다중공선성 문제를 완화하여 변수 간 높은 상관관계로 인한 불안정성을 줄인 안정적 예측을 가능하게 한다.

마지막으로, Random Forest는 회귀 모델인 Lasso와 Ridge가 포착하기 어려운 데이터 내 비선형적 패턴과 복잡한 변수 간 상호작용을 학습하기 위해 추가하였다. 이는 단순 선형 관계를 넘어선 앙상블 모델의 기초적인 예측 성능 기준을 제시하며, Bagging알고리즘 특유의 안정성을 바탕으로 제안 모델(Stacking)의 성능 향상 정도를 보다 객관적으로 검증하기 위함이다. 또, 트리의 개수(n_estimators)를 100으로 설정하고 최대 깊이(max_depth)는 10으로 제한하여 과적합을 방지하였다.

4.3 Evaluation Metrics

본 연구에서는 항공권 가격 예측 모델의 성능을 정량적으로 평가하기 위해 R^2 Score, MAE, RMSE 세 가지 지표를 사용하였다. R^2 Score는 모델이 종속 변수의 전체 분산을 얼마나 잘 설명하는지를 나타내는 지표로, 값이 1에 가까울수록 모델의 설명력이 높음을 의미한다. 이때, 모델의 일반화 성능을 평가하기 위해 Train 데이터와 Test 데이터에서의 R^2 Score를 함께 비교해 과적합과 과소적합 여부를 확인하였다.

또한, 실제 가격 예측의 정확도를 평가하기 위해 MAE와 RMSE를 함께 활용하였다. MAE는 실제값과 예측값의 절대 오차 평균을 계산하여 모델의 평균적인 예측 오차를 나타내며, RMSE는 오차의 제곱 평균에 제곱근을 취한 값으로 큰 오차에 더 민감하게 반응한다. 특히, 항공권 가격은 수요 변화에 따라 급격한 변동이 발생하는 특성이 있기 때문에, RMSE를 통해 모델이 이러한 큰 오차를 얼마나 안정적으로 제어하는지까지 종합적으로 평가하였다. 또한, 데이터 전처리 과정에서는 가격의 왜도를 완화하기 위해 로그 변환을 적용하였다. 하지만 평가 단계에서는 이를 다시 지수 변환하여 원래의 단위인 루피(Rupee)로 복원하여 오차범위를 직관적으로 평가할 수 있게 했다.

4.4 Experimental Setup

학습환경:

본 연구는 Python 3.13.9 기반의 JupyterLab 환경에서 수행되었으며, 데이터 처리 및 모델 구현은 Pandas 2.3.3, NumPy, 그리고 scikit-learn 1.7.2 라이브러리를 중심으로 진행하였다.
대규모 정형 데이터의 효율적인 처리를 위해 Pandas와 NumPy를 활용하였으며, 머신러닝 파이프라인 구성 및 성능 검증에는 scikit-learn을 사용하였다. 또한 비선형 패턴 학습 및 성능 향상을 위해 그래디언트 부스팅 기반 모델인 XGBoost 3.2.0과 LightGBM 4.6.0 프레임워크를 추가적으로 활용하였다. 해당 모델들은 Grid Search CV와 K-fold Cross Validation을 통해 하이퍼 파라미터를 최적화하였다.

Preporcessing:

첫 번째로, 모델의 과적합(Overfitting)을 유발하거나 단순 식별자로서의 기능만 수행하는 편명('flight') 및 불필요한 인덱스('Unnamed: 0') 등의 노이즈 데이터를 일괄적으로 제거하여 데이터의 정합성을 확보하였다. 이후 항공권 예약의 시공간적 특성을 모델이 효과적으로 학습할 수 있도록 특성 공학(Feature Engineering)을 진행하였다. 공간적 특성 측면에서는 기존의 출발지('source_city')와 도착지('destination_city') 변수를 결합하여 '노선(route)'이라는 단일 파생 변수를 새롭게 생성하고 원본 변수들은 삭제하였다. 시간적 특성 측면에서는 비행 출발까지 남은 일수를 의미하는 연속형 변수('days_left')를 출발 직전(1~7일 전), 단기(8~21일 전), 장기(22일 이상)의 세 구간으로 범주화(Binning)하여 '예약 시점(booking_period)' 변수로 재구성해 시점별 가격 변동 패턴을 모델이 명확히 포착하도록 하였다.

종속 변수인 항공권 가격('price')의 경우, 값의 편차가 크고 변동성이 높은 특성을 지니고 있어 모델의 학습 안정성을 저해할 우려가 있다. 따라서, 타겟 변수에 로그 변환(np.log1p)을 적용하여 데이터의 분포를 정규분포에 가깝게 조정하였다. 또한, 기계학습 알고리즘의 원활한 연산을 위해 범주형 변수의 데이터 인코딩(Data Encoding)을 수행하였다. 데이터 간 위계가 존재하는 좌석 등급('class')과 경유 횟수('stops')는 서열적 특성을 반영하여 정수(0, 1, 2)로 매핑하였다. 그 외 명목형(Nominal) 변수들은 가변수 함정(Dummy Variable Trap)을 방지하기 위해 기준이 되는 첫 번째 범주를 제외하는 방식(drop_first=True)의 원-핫 인코딩(One-Hot Encoding)을 일괄 적용하였다. 최종적으로 모델의 객관적이고 신뢰도 높은 성능 검증을 위해 훈련 데이터(Train Data)와 테스트 데이터(Test Data)를 8:2의 비율로 분할하였다.

Hyperparameters:

고성능 부스팅 알고리즘인 XGBoost와 LightGBM의 최적화를 위해 Grid Search 기법을 적용하였다. XGBoost의 경우, 학습의 속도를 결정하는 learning_rate와 트리의 깊이를 제한하는 max_depth를 핵심 최적화 대상으로 설정하였다. 특히 트리의 개수를 나타내는 n_estimators

를 충분히 확보하되, subsample과 colsample_bytree를 각각 0.8로 제한하여 매 학습 단계마다 데이터와 피처의 일부만을 사용하게 함으로써 모델의 일반화 능력을 높였다. LightGBM 또한 유사한 파라미터 그리드를 구성하여 최적화를 수행하였으며, 특히 force_col_wise 설정을 통해 연산 효율을 높이고 verbose 옵션을 조정하여 불필요한 로그 출력을 방지했다.

마지막으로, 메타 러너가 학습 데이터의 타겟값에 직접적으로 과적합되어서 실제 환경에서의 성능이 저하되는 것을 방지하고자 3-fold 교차 검증(cv=3) 방식을 적용하였다. 이는 기본 모델들이 학습 과정에서 참조하지 않은 폴드에 대해 예측치를 생성하게 함으로써 메타 데이터의 데이터 누수를 차단하고 실제 미학습 데이터와 유사한 조건에서 학습되도록 유도한다. 또한, 모델이 데이터의 노이즈까지 학습하여 발생하는 과적합을 막기 위해서 각 모델의 하이퍼파라미터를 최적으로 조정한 뒤 투입하였다. 뿐만 아니라, 모델이 너무 단순화되어 발생하는 과소적합을 방지하기 위해 충분한 수의 n_estimators를 확보하면서 트리의 깊이를 적절히 제한하여 복잡도의 균형을 맞추기 위해 노력했다.

4.5 Results

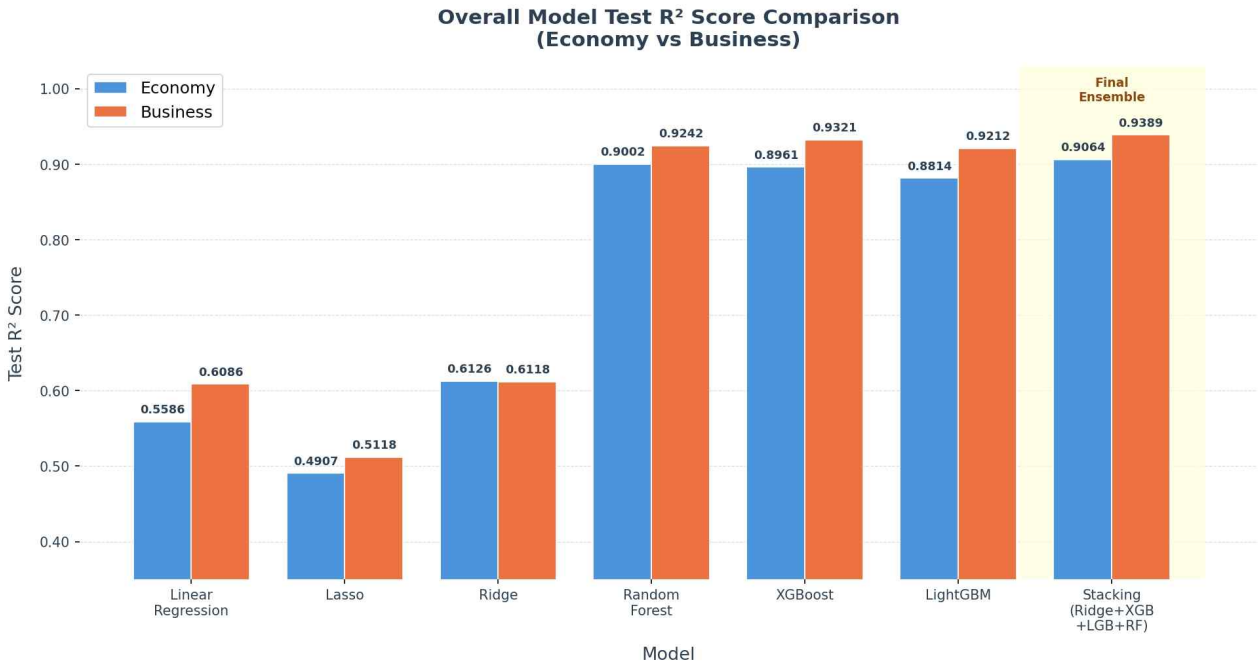

[그림 1]

위 [그림 1]은 각 모델의 등급별 결정계수(R^2)를 비교한 결과이다. 모든 모델에서 선형 회귀 계열 모델보다 트리 기반 앙상블 모델의 성능이 압도적으로 높았으며 최종적으로 제안한 스태킹 모델이 가장 높은 수치를 기록하였다.

본 연구에서 제안한 스태킹 앙상블 모델과 개별 모델들의 성능을 비교 분석한 결과, Economy 등급과 Business 등급 모두에서 스태킹 모델이 가장 우수한 예측 정밀도를 기록하였

다. 특히 Business 등급에서 스태킹 모델의 RMSE는 Ridge 대비 약 55.7%의 오차 감소하였으며, Economy 등급에서도 약 43.3%를 보였다. 이는 단일 모델이 포착하기 어려운 복잡한 가격 변동 패턴을 모델 결합을 통해 효과적으로 학습할 수 있음을 시사한다. 또한, 스태킹 모델은 단일 모델 중 가장 성능이 우수한 XGBoost와 비교하였을 때도 성능 향상을 보이며 모델 간 오차 보정 효과가 존재함을 확인했다.

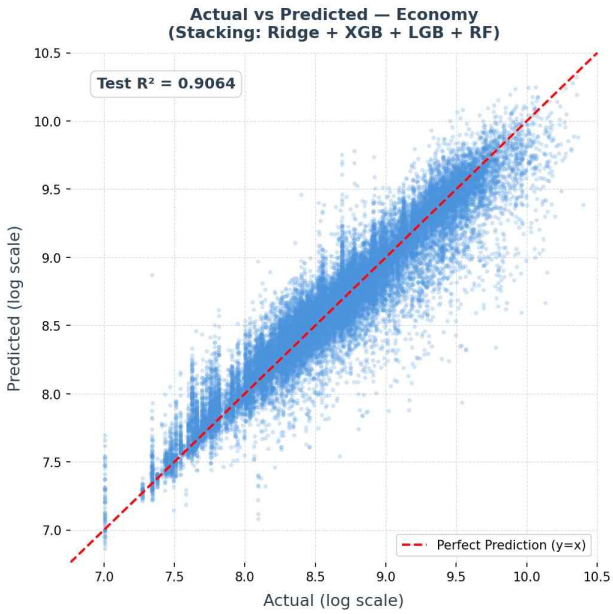

[그림 2]

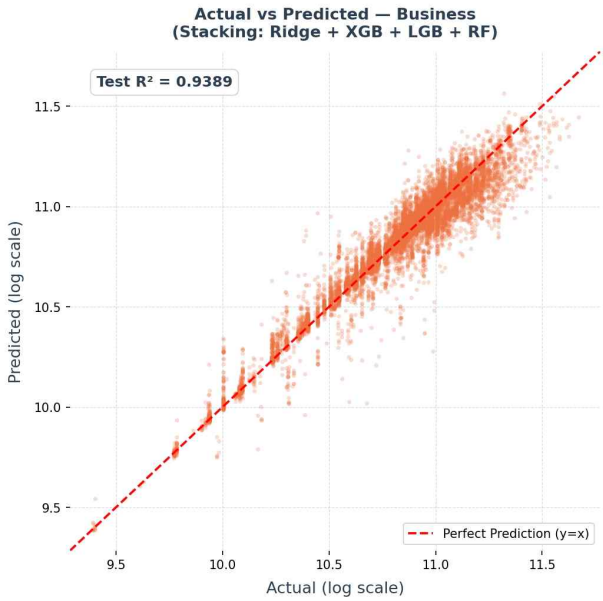

[그림 3]

모델의 실제 예측 성능을 시각적으로 확인하기 위해 [그림 2]와 [그림 3]에 등급별 실제값 대비 예측값의 산점도를 나타내었다. 데이터 포인트들이 기준선(y=x)에 밀집되어 있어 모델이 가격 변동을 매우 정확하게 추종하고 있음을 보여준다.

모델의 가격 결정 요인을 분석하기 위해 특성 중요도와 회귀 계수를 함께 확인한 결과, Economy 등급에서는 특정 항공사(Vistara, Air India)와 예약 시점 변수 등이 영향력이 컸으며 조기 예약 여부가 가격 결정에 지배적 역할을 한다는 점을 시사한다. 반면, Business 등급에서는 경유 횟수(stops)와 운항 시간(duration)이 주요 변수였고 이는 편의성과 이동 효율성이 가격 형성에 중요한 요소로 작용함을 의미한다. 또한, 비즈니스 출장이 잦은 특정 노선(Mumbai-Bangalore)의 영향력이 크게 나타나 도시 간 수요가 가격 결정에 중요한 변수임을 확인할 수 있다.

결론적으로 본 연구에서 제안한 스태킹 프레임워크는 로그 변환된 타겟 변수를 원래의 루피 단위로 복원한 이후에도 안정적인 오차 범위를 유지하였다. 특히, 이상치에 민감한 RMSE 수치가 단일 모델 대비 낮게 형성되었다. 이는 가격의 급격한 변동 상황에서도 강건한 예측력을 보유하고 있음을 뒷받침한다.

추가로 다중선형회귀(Multiple Linear Regression), 라쏘(Lasso), 랜덤 포레스트(Random

Forest) 세 가지 알고리즘을 적용하고 그 성능을 비교 분석한 연구에서는 각 모델의 예측 성능을 결정계수(R^2)를 통해 살펴본 결과, 랜덤 포레스트 모델이 Economy(0.9002)와 Business(0.9242) 모든 클래스에서 압도적으로 높은 정확도를 기록하였다. 이는 항공권 가격 데이터가 가진 복잡한 비선형적 패턴과 변수 간의 상호작용을 랜덤 포레스트가 가장 효과적으로 학습했음을 보여준다. 반면, 선형 모델인 다중선형회귀와 라쏘는 R^2 점수가 0.5~0.6 수준에 머물렀으며, 특히 라쏘 모델은 L1 규제의 영향으로 인해 상대적으로 가장 낮은 성능을 보였다. 이를 통해 항공권 가격 예측에는 단순 다중 선형 모델보다는 데이터의 복잡성을 포착할 수 있는 앙상블 기반 모델이 더 적합함을 실증적으로 확인하였다.

오차 지표(MAE, RMSE) 측면에서도 의미 있는 결과가 도출되었다. 모든 모델에서 이코노미 클래스보다 비즈니스 클래스의 오차가 현저히 낮게 나타났는데, 이는 비즈니스 좌석의 가격 체계가 이코노미에 비해 상대적으로 일정한 규칙성을 가지고 있음을 시사한다. 또한, 중요 변수 분석 결과 모든 모델에서 공통적으로 '남은 예약 기간(days_left)'과 '비행 시간(duration)'이 가격 변동의 핵심적인 요인으로 나타났으며, 랜덤 포레스트는 이러한 변수들의 영향력을 가장 정밀하게 포착하여 낮은 오차율(Business MAE: 0.0370)을 달성할 수 있었다.

결론적으로, 실제 항공권 가격 예측 시스템을 구축할 때에는 비선형 데이터 처리에 강점을 가진 랜덤 포레스트와 같은 알고리즘을 주축으로 활용하는 것이 제일 효과적일것으로 예상된다. 라쏘 회귀를 통한 변수 정제 효과를 확인한 것 또한 유의미했으나, 최종적인 예측 정밀도를 확보하기 위해서는 앙상블 기법의 적용이 필수적임을 알 수 있었다. 본 연구의 결과는 향후 실시간 항공권 가격 변동 예측 서비스나 동적 가격 책정(Dynamic Pricing) 모델의 기초 자료로 유용하게 활용될 수 있을 것으로 기대된다.

5. Limitations

5.1 잠재적 한계점

본 연구에서 사용한 Stacking Ensemble 접근 방식은 항공권 가격 예측에 효과적인 성능을 보였지만, 몇 가지 잠재적인 한계점을 가진다.

먼저, 본 연구에서 사용한 모델은 특정 데이터셋(Clean_Dataset.csv)에 기반하여 학습되었기

때문에 다른 국가나 다른 항공 시장 데이터에 그대로 적용할 경우 성능이 저하될 가능성이 존재한다. 항공권 가격은 지역, 항공사 정책, 수요와 공급 등의 다양한 외부 요인에 영향을 받기 때문에 데이터 분포가 달라질 경우 모델의 일반화 성능이 제한될 수 있다.

또한, Multiple Linear Regression과 Lasso 모델은 변수 간 선형 관계를 가정하므로 실제 항공권 가격과 같은 복잡한 비선형 패턴을 완전히 반영하지 못하는 한계가 있다. 반면, Random Forest는 이러한 비선형 관계를 잘 학습할 수 있지만 모델의 해석 가능성이 낮다는 단점이 있고 다중공선성 문제로 인해 일부 변수의 계수가 비정상적으로 크게 나타나는 현상이 발생할 가능성이 있다. 특히 원-핫 인코딩된 범주형 변수들이 서로 높은 상관관계를 가질 경우, Multiple Linear Regression 계수 해석이 불안정해질 수 있다.

마지막으로, Stacking Ensemble 모델은 여러 모델을 결합함으로써 성능 향상을 기대할 수 있지만 모델 구조가 복잡해지고 계산 비용이 증가하는 단점이 있다. 또한, base model 간의 예측 결과가 유사할 경우 기대한 만큼의 성능 향상이 나타나지 않을 가능성도 있다.

5.2 실험 설계상의 제약 사항

첫째, 모든 모델은 제한된 학습 시간과 컴퓨팅 자원 내에서 수행되었기 때문에 하이퍼파라미터 튜닝이 충분히 이루어지지 못했을 가능성이 있다. 특히 Random Forest 및 Stacking 모델의 경우, 더 많은 트리 수나 다양한 파라미터 조합을 탐색할 경우 성능이 더 향상될 여지가 있다.

둘째, Stacking Ensemble 모델의 경우 교차검증(cv=3)을 기반으로 구성되었지만 비용 증가로 인해 이를 제한적으로 설정하였다. 따라서 보다 안정적인 성능 평가를 위해서는 더 많은 fold를 사용하는 것이 바람직하다.

마지막으로, 본 연구에서는 모델 성능 비교를 중심으로 진행되었기 때문에 각 모델의 세부적인 영향 분석이나 특정 변수 또는 모델 구성 요소를 제거하며 성능 변화를 분석하는 과정은 충분히 수행되지 못하였다. 이는 모델 구조의 최적성을 완전히 검증하는 데 있어 한계로 작용할 수 있다.

5.3 한계점

첫째, 예측 불가능한 외부 변수들로 인해 예측 정확도가 떨어질 수 있다. 항공권 가격은 유가 급등락, 자연재해, 전염병, 정치적 변화, 경제적 변화, 항공사 내부 변화와 같은 비정형 외부 요인에 매우 민감하게 반응한다. 이러한 사건들은 가격 결정 메커니즘을 완전히 무너뜨릴 수 있다. 또한, 이러한 변수들은 수치화하기 어렵고 발생 시점 예측이 어렵기 때문에 모델은 이를 단순한 이상치(Outlier)로 처리하거나 잘못된 방향으로 학습할 위험이 있습니다.

둘째, 노선별 데이터 불균형으로 인해 편향된 예측을 내놓을 가능성이 있다. 이용객이 많은 인기 노선 또는 선호도가 높은 항공사에 비해 운항 횟수가 적거나 선호도가 낮은 항공사의 데이터의 경우, 학습에 필요한 데이터의 양이 부족할 것이다. 이러한 롱테일(Long-tail) 분포 데이터를 사용할 경우 모델이 과적합이 되거나 평균적인 가격으로 편향될 예측을 가져올 가능성이 있다.

셋째, 명절, 연휴, 대규모 축제 직전 등 수요가 폭증하는 구간에서는 항공사의 동적가격 설정 알고리즘이 평소와 다르게 작동할 것이다. 특정 시점에만 발생하는 Sparse Feature를 모델이 충분히 학습하지 못 할 경우, 실제 가격 급등세를 과소평가하는 경향이 나타날 수 있다.

5.4 한계점 개선 및 향후 연구 방향

첫째, 본 연구에서 사용한 데이터셋은 인도 내 주요 6개 도시(델리, 뭄바이 방갈로르, 콜카타, 하이데라바드, 첸나이)에서 2022년 2월 11일부터 3월 31일까지, 총 50일 간 수집된 데이터이다. 이는 지리적 및 시장의 국한성이 있으며 시간적 데이터의 제약이 있다. 따라서 다양한 나라에서 장기적으로 수집된 데이터를 이용하고 실시간 유가지수, 환율 변동, 소셜 미디어상의 여행 키워드 트렌드 등 다양한 외부 지표를 피처로 통합하여 외부 충격에 대한 모델의 강건성을 향상시켜야 한다.

둘째, 데이터 불균형으로 인한 모델의 편향성과 과적합 문제를 해결하기 위해 향후 연구에서는 데이터 증강(Data Augmentation)과 전이 학습(Transfer Learning)을 제안한다. 우선 부족한 데이터의 통계적 보완을 위해서 운영 횟수가 적은 노선에 대해 SMOTE와 같은 샘플링 기법을 적용하여 학습 데이터의 절대량을 확보한다. 또한, 데이터가 많은 인기 노선에 학습된 가격 결정 메커니즘을 데이터가 부족한 비인기 노선의 예측 모델에 이식하는 전이 학습을 도입한다. 예를 들어, 대형 항공사나 유사한 거리의 노선들이 공유한 가격 변동 패턴을 기본 지식으로 먼저 학습시킨 뒤에 개별 롱테일 노선의 특성에 맞춰 세부 튜닝을 하는 방식을 취한다.

셋째, 시간적 맥락을 반영한 피처 엔지니어링의 고도화가 필요하다. 단순히 공휴일 여부를 이진 분류(0 또는 1)로 변수화하는 기존의 방식에서 벗어나, 연휴의 총 길이, 요일 배치, 특정 이벤트와의 간격 등을 수치화한 '수요 지수(Demand Index)'를 생성하여 모델에 반영할 것을 제안한다. 이를 통해 특정 시점에만 발생하는 희소 특징(Sparse Feature)의 가중치를 모델이 정교하게 학습하게 하며, 특수 시즌의 가격 급등 신호를 조기에 감지할 수 있는 모델을 구축할 수 있다. 뿐만 아니라, 외부 실시간 지표와 도메인 지식을 통합한 하이브리드 예측 시스템이 한계를 개선하는 데에 도움이 될 것이다. 또, 실시간 검색 트렌드 및 프로모션 데이터를 통합하여 학습 범위를 확장하고 항공사의 수익 관리(Yield Management) 임계점을 반영한 규칙 기반(Rule-based) 로직을 모델과 결합한다. 이를 통해 정적 데이터 학습의 한계를 극복하고 외부 수요 신호에 기민하게 반응함으로써 실무적인 예측 정확도를 제고할 수 있다.

6. Conclusion

6.1 연구의 목표와 접근 방법 요약

본 연구의 주된 목표는 항공권 가격의 비선형적 변동성을 학습하고 이코노미와 비즈니스 등 좌석 등급별 가격 결정 메커니즘을 정량적으로 분석하여 고정밀 예측 모델을 구축하는 것이다. 따라서 선행되었던 연구들과는 다르게 각 좌석별 데이터를 분리해 연구를 진행했다. 또한, 모델링 접근 방식으로는 타겟 변수 로그 변환 및 예약 시점 구간화 등 고도화된 특성 공학(Feature Engineering)을 적용한 후 베이스라인 모델(LR, Lasso, Ridge) 성능을 평가하였다. 나아가 랜덤 포레스트(Random Forest), XGBoost, LightGBM 등 트리 기반 알고리즘의 장점을 결합하고, 이를 메타 러너인 릿지(Ridge) 회귀로 통합하는 스태킹 앙상블(Stacking Ensemble) 기법을 최종적으로 적용하였다.

6.2 연구를 통해 기대되는 성과

첫째, 강력한 예측 성능을 확보할 수 있다. 단일 기계학습 모델이 지니는 편향과 분산의 한계를 스태킹 앙상블 모델로 상호 보완하며 다중 선형 회귀 수준 (R^2 0.55~0.60) 에 머물렀던 예측 정확도를 (R^2 0.85~0.92) 이상으로 대폭 향상시키고 오차율을 효과적으로 통제할 수 있다.

둘째, 좌석 등급별 상이한 가격 결정 메커니즘의 실증적 규명이다. 특성 중요도(Feature Importance) 분석을 통해서 이코노미 클래스는 '예약 시점(days_left)'이 가격 변동을 주도하는 반면, 비즈니스 클래스는 '총 비행시간(duration)'과 '경유 횟수(stops)' 등 일정의 편의성이 지배적인 영향을 미친다는 것을 정량적으로 증명할 수 있다.

6.3 Future work 및 활용 가능성

본 연구에서 제안한 프레임워크는 다음과 같은 세 가지 방향으로 확장 및 활용될 수 있다.

첫째, 실제 가격 예측 서비스와 시스템에 반영할 수 있다. 개발된 예측 모델을 API 형태의 서비스로 배포하여 소비자에게는 비용 절감을 위한 '최적의 구매 윈도우(Optimal Buying Window)'를 안내하고 항공사 및 여행사(OTA)에는 데이터 기반의 정교한 동적 운임(Dynamic Pricing) 최적화 시스템의 핵심 알고리즘으로 적용할 수 있다.

둘째, 추가 dataset 확장을 통해 복잡한 현실 세계의 변동성을 보다 정확하게 파악할 수 있다. 유가 변동률, 글로벌 인플레이션 지표, 휴일 및 계절적 성수기 요인 등 거시 경제 및 외부 환경 변수 등 항공권 가격을 변화시키는 요소들이 매우 다양하다. 하지만 해당 변수들은 예측이 어렵고 영향력이 상이하므로 핵심 변수의 영향력을 정량화하고 외생 변수에 민감하게 반응하는

모델의 강건성(Robustness) 확보가 중요한 향후 과제가 될 것이다.

셋째, 시계열 특화 하이브리드 구조 채택하면 특정 기간에 대한 오차를 감소시킬 수 있다. 현재의 트리 기반 모델 중심 스태킹에서 벗어나, LSTM이나 GRU 같은 순환 신경망(RNN) 또는 Prophet과 같은 통계적 시계열 모델을 베이스 모델로 추가할 수 있다. 이를 통해 항공권 가격의 계절적 주기성과 장기 트렌드를 보완하여 성수기나 연휴 기간의 예측 오차를 획기적으로 줄일 수 있을 것이다.

참고문헌(Reference)

[1] T. Kalampokas, et al., "A Holistic Approach on Airfare Price Prediction Using Machine LearningTechniques," IEEE Access, vol. 11, 2023. doi: 10.1109/ACCESS.2023.3274669.

[2] T. Deng, "International flight fare prediction and analysis of factors impacting flight fare," Theoretical and Natural Science, vol. 31, no. 1, pp. 329-335, 2024.

[3] M. Erturk, M. Emec, A. A. Saridogan, and N. Kucukgergerli, "Large-scale airline ticket price prediction using ensemble learning," DergiPark, 2025. [Online]. Available: https://dergipark.org.tr/tr/download/article-file/4957193

[4] H. Korkmaz, "Prediction of airline ticket price using machine learning method," Journal of Transportation and Logistics, vol. 9, no. 2, pp. 205-218, 2024. doi: 10.26650/JTL.2024.1486696.

[5] A. Chavan, I. Rathod, and S. Bobde, "Comparative Analysis of Machine Learning Models for Accurate Flight Price Prediction," International Journal of Innovative Science and Research Technology, vol. 9, no. 9, pp. 2798-2804, 2024.